

iPAS AI 應用規劃師（初級） 備考三冊 2026-11-07

第二冊 內容讀書重點筆記

科目一與科目二完整重點。請搭配第一冊進度表與第三冊題本。

整理：讀書筆記（非官方教材原文）。公告試題僅供個人備考練習。

科目一 人工智慧基礎概論

科目一讀書重點 | 人工智慧基礎概論

對齊官方《學習指引》科目一第三章。本筆記是備考整理，不是指引原文。讀完對應節，用「判斷句」閉卷講一遍。勘誤先看 勘誤必記。練習用 04-題本。

考試：約 50 題選擇、電腦測驗。出題常是企業情境＋「何者有誤／最不適當」。科目一高頻：資料與特徵、統計檢定、學習類型、鑑別 vs 生成、XAI、技術選型。

3.1 人工智慧概念

3.1.1 定義與功能分類

判斷句： AI 是讓機器執行原本需要人類智慧的任務（學習、推理、解題、感知）。它是一個領域，不是單一技術；機器學習、深度學習、專家系統都只是其中一塊。

依**功能**分三類（常考對場景，不要只背名字）：

類型	在做什麼	典型產出	企業例子
分析型	從資料找出模式與洞見	報表、分群、關聯	客群分析、品質異常探勘
預測型	用歷史資料預測未來	分數、趨勢、風險	流失預測、授信、需求預測
生成型	依提示產出新內容	文字、圖、語音、程式	客服草稿、方案一頁紙

易混： ChatGPT 能幫忙分類，不代表「分類題」一定要上生成式。要判定／打分數 → 先想鑑別／預測模型；要產出內容 → 生成式。

AI ≠ 只有深度學習。正確說法：AI 包含機器學習、專家系統、搜尋演算法等。深度學習是機器學習的子集合。

3.1.2 企業導入 AI 的常見目標

提高效率、強化決策、個人化服務、促進創新。生成式自 2022 年後大幅改變工作型態，但**高風險決策仍要人在迴路**（見治理）。

3.1.3 應用領域（記「場景→技術」，不背廠商）

產業	常考場景	技術方向
醫療	影像輔助診斷、藥物分子模擬、個人化療程	CV／生成分子／不可全自動下診斷
金融	信用風險、詐欺即時偵測、演算法交易	預測／異常偵測；授信要人覆核
製造	重複作業自動化、影像瑕疵、預測性維護	機器人+CV+設備時序
交通	自駕、流量預測、路線	感測+強化學習／預測
娛樂	適應性遊戲、VR、內容推薦	生成+推薦系統

公告題考法：智慧城市要持續蒐集 PM2.5、垃圾桶滿溢 → 最直接是**感知器網路（Sensor Network）**，不是專家系統或決策支援系統。先問「資料從哪來」。

3.1.4 三層架構

1. 技術底層

- 資料處理與分析：清理、整合、儲存；ETL；Hadoop／Spark 等大數據平台。
- 演算法：迴歸、分類、決策樹、基因演算法等。
- 機器學習：監督／非監督／強化。
- 深度學習：多層神經網路，處理影像、語音、NLP；框架如 TensorFlow、PyTorch。
- 專家系統：規則+知識庫，模擬專家決策（醫療、財務）。

1. **開發應用：**模型設計 → 訓練 → 測試 → 部署，對準業務需求。

2. **實際運用：**行業方案、產品服務、流程優化。

判斷：「先選模型品牌」通常錯；先對準資料與任務，再選底層技術。

3.1.5 資料型態與蒐集

型態	特徵	例子
結構化	固定欄位、列存	關聯式資料庫、規範化試算表
半結構化	有標籤、格式較彈性	JSON、XML、CSV
非結構化	無固定 schema	圖、影音、郵件、自由文本

蒐集方法：問卷調查、自有產品／裝置數據、公開 API、付費第三方、網路爬蟲（公開頁面）。
規劃時同時間：授權、個資、能不能外流。

3.1.6 資料清洗

目的：處理遺缺、重複、錯誤、不一致。

- **遺缺**：均值／中位數／眾數填補、插補、用模型預測；缺太多才刪列（會傷代表性）。
- **重複**：用主鍵或關鍵欄位識別，留一份。
- **錯誤值**：超出合理範圍（年齡 -5）、拼寫錯誤。
- **離群值**：可能是錯，也可能是有意義的極端事件（高額理賠）。**不要一律刪**。先用 Z-score／IQR 評估，再依業務決定調整或保留。公告題：常態資料裡少數極端高額案件，最不適當的是不評估就粗暴刪掉或破壞整體分佈。

資料整合（Data Integration）目的：統一格式與欄位、去重、整併多源以提升完整性。**不是**為了依保存政策延長原始資料留存期限。

3.1.7 資料轉換

- 格式轉換（CSV↔JSON）
- 型別轉換（字串→數值）
- **正規化／標準化**：縮放到可比範圍，消除單位差異（Min-Max、Z-score）
- **離散化**：連續變數切區間（年齡→青／中／老）
- **縮減**：特徵選擇、特徵提取、**PCA** 降維

類別編碼：無序類別用 One-hot；Label encoding 可能被模型當成有大小順序。

3.1.8 四種分析（必考對任務）

分析	問題	工具印象
敘述性 Descriptive	發生了什麼？	平均、中位數、標準差、百分位、直方圖、散佈圖、折線圖
探索性 Exploratory	有什麼模式／異常？不預設假設	散佈圖矩陣、熱圖、平行座標、盒鬚圖、相關、分群、PCA、異常偵測
診斷性 Diagnostic	為什麼發生？	向下鑽取、關聯（Apriori／購物籃）、因果（A/B、因果圖）
預測性 Predictive	接下來會怎樣？	迴歸、分類、時間序列（ARIMA／LSTM）、集成（RF／GBM／XGBoost）

EDA vs CDA：EDA 靈活探索、生成假設；CDA（驗證性）驗證假設、做分類／分群／相關／預測。不要把「先畫圖看看」說成驗證性。

敘述統計選指標：

- 平均：好算，**怕極端值**。

- 中位數：不怕極端值；房價有豪宅時用它。
- 眾數：最常見類別；可能多個或不存在。
- 標準差：分散程度；品管上標準差大 → 製程不穩、良率差。
- 百分位：描述分佈，較不受極端值左右。
- 直方圖：看分佈；組距選不好會誤導。
- 散佈圖：兩變數關係。
- 折線圖：時間趨勢；不適類別比較。
- 雷達圖不適合做資料分佈估計（指引練習題）。

偏態口訣：

- 平均 > 中位數 → 常為**正偏**（右尾長，被大值拉平均）。
- 平均 < 中位數 → 常為**負偏**。

3.1.9 搜尋演算法

- **線性搜尋**：從頭比到尾。未排序也可用。
- **二分搜尋**：資料必須已排序；比中間、砍一半。
- **DFS**：沿一條路走到盡頭再回溯。
- **BFS**：一層一層擴散。

3.1.10 三個基礎模型

線性迴歸：預測連續值（房價、銷額）。假設線性；非線性擬合差。找一條最貼資料的直線／超平面。

邏輯迴歸：名字有迴歸，其實是**分類**。Sigmoid 把輸出壓成 0-1 機率，再設閾值（如 0.5）。優點：好懂、有機率意義。基本型是二元，多類要擴展。

KNN：看最近的 K 個鄰居。分類用多數決；迴歸用平均或中位數。K 是鄰居數，不是群數（群數是 K-means 的 K）。

3.1.11 機器學習步驟與學習類型（3.1 已出現，3.3 再加深）

步驟：(1) 準備資料（蒐集、去雜訊、前處理）→ (2) 訓練並調參 → (3) 測試評估，不好就換模型重來。資料愈多且處理愈完整，通常愈好。

類型	要不要標籤	任務	例子
監督式	要	分類、迴歸	垃圾信、房價
非監督式	不要	分群、降維、異常	客群、壓縮
強化學習	獎懲	與環境互動、最大化累積獎勵	圍棋、自駕

非監督式**不是**「學習輸入與既定標記的對應」——那是監督式。

3.1.12 深度學習三經典

CNN：影像。卷積抽局部特徵 → 池化降維防過擬合 → 全連接做分類／迴歸。層次特徵：邊緣 → 物體。應用：人臉、MNIST、物件偵測、醫學分割。

RNN：序列。有記憶，適合語音、文本。缺點：梯度消失／爆炸、長序列慢。改良：**LSTM**（遺忘／輸入／輸出門）、**GRU**（較簡、效果常接近）。現代長依賴與 NLP 多改走 Transformer。

GAN：生成器生假資料、判別器辨真假，互相對抗。優點：高品質樣本。缺點：訓練不穩、**模式崩潰**（Mode Collapse）、算力大。應用：草圖轉寫實圖、語音合成。GAN 結果**不是**高度可解釋。

3.1.13 生成式模型怎麼練

原理：學文字（或資料）的機率分布，依提示逐 token 接下去。參數愈多，通常愈能捕捉細微差異。

兩階段：

- 1. **預訓練**：大量資料 → 清洗 → 向量化 → 選模型（GAN／VAE／Transformer）→ 損失＋優化器（Adam、SGD）迭代到收斂。
- 2. **微調**：用領域資料再練；調學習率、batch；可加任務層；資料增強。

影響效果：資料品質與多樣性、模型結構、超參數、計算資源。

生成式**最核心能力**是生成新的、原創的內容，不是「會算數學」或「會控制機器人」。重要基礎是**神經網路**，不是決策樹或線性迴歸。

3.1.14 治理與透明（公告題常考）

- 高風險（醫療診斷結論、自動拒貸、自動裁員）→ **Human-in-the-loop**，準確率高也不能無人審核。
- 透明：對受影響的人講得懂；適當對外揭露（報告、技術文件、網站），不是「全部保密」或「只跟內部講」。
- 公平：訓練資料偏誤會變成歧視；要補資料、審核、監控。
- 國際合作：標準、防濫用、技術移轉——「以上皆是」類題出現時通常對。
- 台灣情境：公部門對照數發部手冊思路；金融對照金管會金融業 AI 指引。

資料隱私技術（規劃判斷）：

做法	一句話
去識別化	拿掉直接認人欄位，仍可能再識別
差分隱私	加噪音，單筆難反推

做法	一句話
聯邦學習	資料不動、模型動

Data leakage：測試集或未來資訊混進訓練 → 分數虛高、上線崩。時序資料亂打散是經典陷阱。

3.2 資料處理與分析概念（統計必配勘誤）

3.2.1 中央趨勢

- **平均數**：算術平均最常用；易被極端值拉走。另有幾何、調和平均，考場以算術為主。
- **中位數**：排序後正中；不怕極端值；複雜推導較不便。
- **眾數**：出現最多次；不受極端值；可能多個或沒有。類別資料常用眾數。

3.2.2 分散度（含勘誤）

- **四分位數**：排序後切四等分的三個切點。
- **全距 Range**：最大減最小；只看兩端，不精確，怕極端值。
- **IQR**： $Q3 - Q1$ 。描述中間 50%。指引原文說「與全距有一樣的缺點」，練習題正確選項是「IQR 是 $Q3$ 與 $Q1$ 的差」。解題：IQR **較不受極端值影響**（相對平均、全距）。若選項寫「IQR 會受極端值影響」通常是陷阱。
- **平均差 Mean Deviation（勘誤）**：所有觀察值與平均數之間**絕對差值的平均**。越大越分散。不是只說「差距」而不提絕對值與平均。
- **標準差**：點離平均的遠近。品管：標準差顯著偏大 → 製程波動大、品質不穩。
- **變異係數等**：用來比較不同單位或不同平均水準的分散。

3.2.3 抽樣變異與統計推論（勘誤）

抽樣變異：從母體抽樣算出的統計量（樣本平均、樣本標準差），因樣本隨機性而與母體參數不同，這種變動叫抽樣變異。

機率模型用來刻畫這種變異，才能做區間估計與假設檢定。

統計推論（勘誤）：根據樣本資料，判斷是否接受或拒絕統計假設的過程。

3.2.4 統計方法粗分

- **無因果取向**：敘述統計、交叉、卡方、PCA、因素分析、集群、相關。
- **有因果／預測取向**：羅吉斯迴歸、區別分析、迴歸、變異數分析、PLS 等。

相關 $\neq$ 因果。診斷分析才認真做因果（實驗、A/B）。

3.2.5 假設檢定名詞（表已勘誤）

流程：猜想 $\rightarrow$ 蒐集資料 $\rightarrow$ 檢定決策（接受或拒絕）。

名詞	要記住的意思
H0 虛無假設	沒有顯著效果／差異，檢定的基準
Ha 對立假設	有顯著效果／差異
簡單假設	參數完全指定
複合假設	只指定部分參數
接受域／拒絕域	讓 H0 被接受／被拒絕的樣本結果集合
顯著水準 α	事先得容許的 Type I 上限，常取 0.1／0.05／0.01
檢定統計量 T	用樣本算出來決定是否拒絕 H0
p 值	H0 為真下，出現「至少跟觀測一樣極端」的機率。 $p < \alpha \rightarrow$ 拒絕 H0

錯誤表（勘誤後，必背）：

	H0 為真	H0 為假
接受 H0	正確	Type II (β) 漏放
拒絕 H0	Type I (α) 冤案	正確（檢力）

原文表格曾把「拒絕 H0 且 H0 為真」誤寫成 Type II。正確是 **Type I**。

$p=0.03$ 、 $\alpha=0.05$ （勘誤後說法）：在 95% 信心水準下拒絕虛無假設。

- 不是「有 97% 信心」（1-0.03 的誤用）。
- 不是「這次犯錯機率就是 5%」。5% 是事先設定的 Type I 上限，不是這次實際犯錯機率。
- $p < \alpha$ 所以可以拒絕 H0，不是「無法拒絕」。

3.2.6 K-means（3.2 練習＋勘誤）

做法：指定 K 個中心 $\rightarrow$ 點分配到最近中心 $\rightarrow$ 更新中心 $\rightarrow$ 反覆，最小化平方誤差。

正確特徵：

- 希望 K 個互不重疊的群。
- 起始中心不同，結果可能不同。

- 容易受雜訊與離群值影響中心。
- 適合球形、大小密度接近的群。
- 不適合明顯非球形、密度差很大、很多離群。
- 常與 PCA（降維）、Elbow（選 K）搭配，使用上有彈性。
- 原理相對簡單，不是「比其他集群法複雜」。勘誤：練習第 3 題「並非特點」應選「原理相對複雜」。

K-means 不擅長直接處理類別型資料（「可以處理類別型」是不正確敘述）。

K = 要分成幾群，不是特徵數、樣本數、迭代次數。

3.3 機器學習概念

3.3.1 原理與挑戰

機器學習：從資料學規律，**沒見過的資料也要準**（泛化），不是背訓練集。三大類型：監督、非監督、強化。

優勢：資料驅動、可處理非結構化、可隨資料擴展。

挑戰（常考「還要管什麼」）：資料品質不均、標註貴、**解釋性不足**、隱私與倫理、偏見造成歧視。醫療／法律尤其要能解釋。

未來方向：可解釋、公平去偏、跨領域整合。

3.3.2 監督式：常見模型

- **線性迴歸**：連續值。
- **SVM**：找最大間隔超平面；核函數處理非線性。二元分類常用；醫療影像良惡性等。
- **神經網路**：非線性、複雜資料；語音轉文字等。
- **決策樹**：規則清楚，**可解釋性好**（指引練習強調這點）。
- **隨機森林**：多棵樹投票／平均；Bootstrap 抽樣；降過擬合、較穩。

監督式特點：每個樣本有輸入＋標記；學 mapping。

3.3.3 非監督式

聚類（K-means、層次）＋降維（PCA）。市場區隔、異常偵測、影像壓縮、基因資料。不靠事先標籤。

3.3.4 強化學習細節

三要素：**Agent、環境、獎勵**。目標最大化累積獎勵。適合動態、重複互動、長期規劃（圍棋、自駕）——指引練習第 1 題答案。

流程：狀態 → 依策略選行動（探索 vs 利用）→ 環境給新狀態與獎勵 → 更新策略。

- **Q-Learning**：學每個（狀態, 行動）的長期價值 Q ，選 Q 最大的行動。
- **DQN**：用深度網路近似 Q ，因狀態太多無法用 Q 表。搭配經驗回放、目標網路穩定訓練。

3.3.5 機器學習三階段

1. **資料處理**：清洗（均值／中位數填補、刪高缺失、IQR 或標準差處理異常）→ 標準化（Min-Max 映到 0-1；Z-score）→ 特徵選擇／降維。
2. **模型訓練**：選演算法、損失函數、優化器；**梯度下降**用來更新參數、最小化損失。
3. **評估與優化**：訓練／驗證／測試切分；交叉驗證估泛化；調超參數。

過擬合：訓練很好、測試很差（高 variance）。原因常是模型太複雜或資料不夠、學到雜訊。處理：更多資料、簡化模型、**正則化（L1／L2）**、Dropout、早停、資料增強。指引練習：降低過擬合「通常」選增加正則化項（選項若同時有「增加模型複雜度」那是反效果）。

欠擬合：訓練測試都差（高 bias）→ 模型太簡單或特徵不夠。

交叉驗證目的：較穩地估泛化、減少單一次切分的運氣，協助選模型／超參。

3.3.6 評估指標陷阱

- 只看 Accuracy：類別不平衡會騙人（99% 負例全猜負例也很高）。
- 看 Precision／Recall／F1、混淆矩陣。
- 高分先問：切分有沒有 leakage？時序有沒有用未來？

L1（Lasso）讓權重稀疏、有特徵選擇味道；L2（Ridge）讓權重平滑。

深度學習與監督式**不互斥**：CNN 影像分類仍是監督式。

機器學習三核心要素常見考法：**資料、演算法（模型）、計算能力**（或資料／模型／評估，依選項選最完整的一組）。

3.4 鑑別式 AI 與生成式 AI

3.4.1 一句話分邊

	鑑別式 DAI	生成式 GAI	
學什麼	條件機率 $P(y x)$	x ，找決策邊界	聯合／邊際分佈 $P(x,y)$ 或 $P(x)$ ，再抽新樣本
輸出	類別、分數、偵測框	新的文字、圖、聲音、程式	

	鑑別式 DAI	生成式 GAI
同一輸入	應盡量穩定同一判斷	允許變異（同一 prompt 不同輸出是特徵）
風險	偏誤、誤判成本、漂移、標註成本	幻覺、智財、洩密、不可控、算力
驗證	標註集、混淆矩陣、上線監控	人工抽樣、引用、紅隊、回歸測試

生成使用者會反覆改 prompt，直到任務可接受——這叫提示工程，不是模型壞掉。

3.4.2 鑑別式模型速查

- 邏輯迴歸：二元分類、MLE、閾值。
- SVM：最大間隔＋核。
- 決策樹：資訊增益／吉尼；好解釋。
- 隨機森林：集成、穩。
- 神經網路：反向傳播調權重；影像／語音／自駕感知。

3.4.3 生成式模型速查

- **GAN**：生成器 vs 判別器。StyleGAN 人臉、風格遷移、稀缺病變影像、VR 場景。
- **VAE**：Encoder 壓到隱空間、Decoder 重建；平滑、可做異常檢測（偏離學過的正常分佈）、缺損修復。
- **擴散模型**：加噪到高斯再逐步去噪還原。高解析圖像、文生圖。
- **Transformer／LLM**：自注意力、可平行；現代 NLP 主力。

3.4.4 整合應用（規劃題高分）

生成負責造資料／造內容，鑑別負責判斷。

- 醫療：GAN 補稀缺病變圖 → CNN 分類。
- 金融：生成壓力情境 → 鑑別風險。
- 自駕：生成惡劣天氣場景 → 鑑別決策。
- 客服：鑑別意圖／情緒＋生成回覆；知識要準就加檢索。
- 語音：ASR（鑑別）＋TTS（生成）。
- 教育／智慧城市：生成多樣情境，鑑別做個人化或預警。

規劃口訣：要判定走鑑別；要產出走生成；兩者常串。不要為了生成而生成。小鑑別模型可能比 LLM 分類更便宜、更穩。

上線後準確率掉 → 先查**資料漂移**、資料品質、標籤定義是否變了，再重訓或改規則。

3.4.5 可解釋 AI (XAI) ——公告試題必考，指引較薄

目的：讓人理解「為什麼這樣判」，高風險（授信、醫療、合約風險）幾乎必問。

技術	是什麼	選它的時候
內建可解釋 (Intrinsic)	模型本身透明（線性、淺決策樹）	要從頭到尾可追規則
LIME	局部 、模型無關：在該筆資料附近，用簡單代理模型近似黑盒子	解釋 這一筆 為什麼被拒貸
SHAP	用 Shapley 值把預測拆成各特徵的貢獻（可加總）	要看各特徵對分數的貢獻方向與大小
顯著性圖 Saliency Map	看輸入哪些位置對輸出影響大（影像像素、文本 token）	醫師要看「模型盯哪裡」
反事實 Counterfactual	「若某特徵改成這樣，決策就會翻轉」	對客戶溝通：收入再高 10 萬可能通過

易混：

- LIME 的代理模型是**局部近似**，不是把整個黑盒子變成一棵全球決策樹。
- SHAP 不是準確率指標，是**特徵貢獻**。
- 對客戶講反事實，對工程師才堆 SHAP 圖。
- 「準確率高」不能取代解釋與申訴機制。

3.4.6 科目一解題習慣

1. 先劃任務：分析／預測／生成？監督／非監督／強化？
2. 資料：型態、清不乾淨、有沒有 leakage、能不能出域。
3. 「最不適當」常常是：高風險全自動、刪離群不評估、用錯圖（雷達圖看分佈）、把相關當因果、K-means 處理類別、p 值解釋成 97% 信心。
4. 治理：人、透明、公平、問責。

科目一閉卷清單

- 分析／預測／生成各舉一個樂雲或客戶場景。
- 結構化／半／非結構化各一例。
- 四種分析對任務。
- Type I／II 表、p 與 α 、平均差定義。

- K-means：簡單、怕離群、球形、K=群數。
 - 過擬合 vs 欠擬合。
 - DAI vs GAI 輸出差在哪。
 - LIME／SHAP／顯著性圖／反事實各一句。
-

補篇 A | 訓練細節（指引 3.3 後半，公告題會考）

A.1 標準化兩個公式（不考手算，考「何時用、洩漏」）

Min-Max：把值映到 0–1。公式： $\text{scaled} = (x - \min) / (\max - \min)$ 。

Z-score：轉成平均 0、標準差 1。公式： $\text{scaled} = (x - \text{平均}) / \text{標準差}$ 。

對梯度下降類演算法，特徵量尺差很大時一定要做。

評估正確性：min/max 或 μ/σ 只能用**訓練集**算，再套到驗證／測試。用全資料算再切分 = 另一種 leakage。

金額類右偏很大時，常先取 log 再標準化，比直接砍極端值更不破壞分佈。

A.2 特徵選擇三法

方法	做法	印象
Filter	用相關、統計量先篩（Pearson）	快、不管後續模型
Wrapper	用模型分數評估特徵組合（RFE）	準但慢
Embedded	模型自己選（LASSO／L1）	訓練時順便做

降維主力仍是 PCA：壓縮冗餘、保留主要訊息。

A.3 損失與優化器

損失 = 預測跟答案差多少。訓練就是用優化器把損失壓下去。

- **MSE**：迴歸，平方誤差平均。
- **交叉熵**：分類，比機率分佈。
- 輸出要「各類機率且加總為 1」→ Softmax（推薦多類、影音類型預測）。

優化器：

- **BGD**：整批資料算一次梯度，穩但慢。

- **SGD**：一筆就更新，快但不穩。
- **Adam**：自適應學習率，實務最常見。

梯度下降的用途：**更新參數、最小化損失**，不是拿來降雜訊或減計算量。

過擬合防範組合：L1／L2、Early Stopping（驗證集開始變差就停）、Data Augmentation（旋轉翻轉等）。

A.4 評估與調參

指標	何時
Accuracy	類別大致平衡
Precision	誤報代價高（亂抓詐欺傷害客戶）
Recall	漏報代價高（癌症篩檢、洗錢漏放）
F1	不平衡、要 Precision 與 Recall 折衷
MSE	迴歸

醫院篩癌要盡量找出所有可能患者 → 重視 **Recall**（降漏診／False Negative）。

詐欺極少、模型全猜正常也能高 Accuracy → 改看 Recall／F1，或用 **SMOTE** 等合成少數類（仍要小心合成樣本不像真詐欺）。

K-fold：切 K 份，輪流當測試，平均分數。目的是較穩估泛化、**降低過擬合帶來的誤判**（指引練習選此方向），不是加速訓練。

調參：Grid Search 窮舉；Random Search 高維較划算；Bayesian Optimization 用歷史結果接著找。

A.5 學習類型補丁（公告題愛考「配對」）

情境	選
有五年已標註洗錢／正常交易	監督式分類
葉片影像只有 30% 有標籤	半監督式 （用無標資料幫忙）
影像裡標出煙霧位置與範圍	物件偵測／分割，不是只做整張分類
設備感測無完整異常標註、找不像平常的型態	非監督異常偵測
車隊調度依狀態拿獎勵	強化學習
客服 LLM 要更符合組織規範與偏好	RLHF （人類回饋強化學習），不是再做一次非監督分群

情境	選
少量標註＋大量相似產品經驗可遷移	遷移學習
同時用文字通報＋路口影像＋車流	多模態；先整合再建模

結構化預測：輸出是有結構的（序列標註、語法樹、路徑），不是單一類別。判斷「這張圖是貓」是普通分類。

CNN 最適合：影像空間結構（PCB 瑕疵、葉片、安全帽）。時序到站預測更常是時間序列／LSTM／表格＋路況特徵，不是硬套 CNN。

訓練誤差幾乎不降、梯度傳不動 → 懷疑梯度消失；方向是更好的活化、殘差、正規化、換 LSTM／Transformer，不是再加深沒處理的 RNN。

A.6 推論架構

- **即時推論**：低延遲（詐欺當下、自駕、對話）。
- **批次推論**：可等、一次算大量（夜間流失評分、報表）。
- **LLM Batching**：把多個請求湊一批提高 GPU 利用率；可能讓單筆等待變長。高併發要吞吐時合理，極低延遲場景要權衡。

弱 AI 專才、強 AI／AGI 通用：考場幾乎都是弱 AI。某視覺模型只會特定瑕疵 → 換新品種要重訓或遷移，不是已經是通用智慧。

A.7 生成式補丁（科目一也會考）

對話型工具基礎多是 **Transformer／LLM**，不是決策樹。

服裝設計要多樣高品質圖 → 擴散或 GAN 類生成，不是 SVM。

會議摘要用生成；再加一套評估正確性 → 鑑別／檢查模型，兩者整合。

VAE 適合「依既有圖像產生有變化且連續可調的樣本」（隱空間插值）。

Flash Attention：加速 Transformer 注意力運算、降記憶體，不是改成 RNN。

補篇 B | 指引風格自測（先自己選再看答案）

以下改寫自指引各節評量方向，用來閉卷，不是公告試題原文。

B.1 概念

1. 圍棋、自駕這種動態重複互動 →？（強化學習）

2. AI 是否等於深度學習？→ 否，還包含 ML、專家系統等。
3. 提升透明性：對外揭露報告／文件／網站，不是全面保密。
4. 不適合作分佈估計：雷達圖。
5. K-means 的 K：群數。
6. 降過擬合常見項：加正則化（也可更多資料；加複雜度是反效果）。
7. 生成式最核心：生成新內容。
8. 生成式重要基礎：神經網路。
9. 治理國際合作：標準、防濫用、技術移轉，常為「以上皆是」。

B.2 統計

1. K-means 「不正確」：可以處理類別型。
2. 製程標準差顯著偏大：品質不穩。
3. 「並非」 K-means 特點：原理比別的集群複雜。（勘誤）
4. CDA 相對 EDA：驗證假設並深入挖。
5. 房價有豪宅：用中位數。
6. 平均 < 中位數：負偏。
7. $p=0.03$ 、 $\alpha=0.05$ ：95% 信心水準下拒絕 H_0 。（勘誤）
8. 平均 > 中位數：正偏。
9. IQR： Q_3-Q_1 。
10. 類別最常見值：眾數。

B.3 機器學習

1. 三核心要素：數據、模型、損失函數。
2. 監督式：資料含標記。
3. 過擬合主因：過度學習雜訊。
4. 交叉驗證：降低過擬合風險／較穩估泛化。
5. 梯度下降：優化參數以最小化損失。
6. 線性迴歸最適：銷售額等連續預測。
7. 決策樹最大優勢：可解釋。
8. 神經網路差別：多層學複雜特徵。
9. GAN 正確：生成器＋鑑別器。
10. 隨機森林：多棵樹投票／平均。

B.4 鑑別 vs 生成

1. 鑑別式主要目標：分類或迴歸。

2. 生成式模型例子：GAN（SVM／邏輯迴歸／RF 是鑑別）。
 3. 生成式應用包括合成資料、模擬分佈、創作；不包括「只做決策邊界分類」。
 4. 整合價值：生成補資料、鑑別做判斷；客服生成回覆＋鑑別過濾不當內容。
-

補篇 C | 公告題考法判斷卡（科目一）

不要背題號，背「看到關鍵字選什麼」。完整題在 04-題本。

資料

- 資料整合目的不含「延長保存期限」。
- JSON/XML 是半結構化；MySQL 訂單是結構化；郵件圖片是非結構化。
- 正規化／標準化的統計量用訓練集。
- 無序類別不要當有大小的數字；需要互動可用 feature crossing 或樹模型。
- 稀疏類別＋數值並存：樹模型或 embedding，不要只 One-hot 爆炸後硬塞淺線性。
- 直方圖：看單一連續變數分佈（年齡）。散佈圖：兩變數。折線：時間。
- 已排序陣列找值：二分搜尋。

治理與醫療金融

- 金融對消費者互動：要揭露使用 AI、影響、申訴等；不必揭露模型原始碼或權重當「必要項」（依選項選「非必要」）。
- 公部門釋出可能認人的資料：去識別仍可能再識別，要最小化、審查、法律依據。
- 高風險用人覆核＋可解釋＋申訴。

XAI 速配

- 解釋「這一筆」→ LIME（局部代理）。
- 特徵貢獻可加總 → SHAP。
- 影像／文本哪裡被盯 → 顯著性圖。
- 對客戶說「怎樣改就過關」→ 反事實。
- LIME 屬模型無關的**事後局部**解釋，不是 Intrinsic 內建透明模型本身。

技術選型速配

- 訓練 98%、測試差很多 → 過擬合。
 - 類別極不平衡還只看 Accuracy → 錯。
 - 只要區域位置 → 偵測／分割，不是分類。
 - 缺標註 → 半監督或非監督，不要假裝已有完整標籤。
 - 工廠要快驗證、缺 AI 人力 → No/Low Code 或現成服務試點（科目二也考，科目一綜合題會出現）。
-

補篇 D | 整合應用再記一遍

生成不穩：模式崩潰、梯度消失 → 改進 GAN（如 WGAN）、較穩優化。

生成會放大偏見 → 去偏、審核多樣性，再交給鑑別，否則歧視被放大。

架構：生成與判斷分層，中間交換資訊；資料分布變了要能調。

客服：生成多樣回覆，鑑別過濾不當。

內容工廠：生成稿件，鑑別做合規與品質。

這就是科目一 3.4「整合」在企業題裡的樣子。

科目二 生成式 AI 應用與規劃

科目二讀書重點 | 生成式 AI 應用與規劃

對齊官方《學習指引》科目二第三章。本筆記是備考整理，不是指引原文。115-2 公告試題比 115-1 更常考 Agent、Low-Code、導入風險。練習用 04-題本。勘誤：導入第（3）點標題見下文。

考試：約 50 題選擇。高頻：導入風險、技術選型（RAG vs 微調 vs Agent）、Low-Code、提示與採樣、TCO／ROI、個資與幻覺。

解題口訣：先問問題與資料能不能用，再選工具；治理不因為 No Code 或 ChatGPT 而消失。

3.1 No Code / Low Code 概念

3.1.1 定義

AI 民主化：用視覺化降低門檻，讓非工程背景也能參與做 AI 應用。

	No Code	Low Code
怎麼做	拖放、範本、幾乎不寫程式	視覺化為主，少量程式補足
適合誰	業務、快速原型、小型內部工具	有技術背景、中大型、要客製與整合
彈性	低	較高
風險	天花板、廠商鎖定、稽核不透明	仍有鎖定，但較能接 API

TensorFlow／Keras 等也有視覺化介面，讓無程式經驗者能組 ML 流程——考的是「降低門檻」，不是叫你背操作步驟。

生成式 AI（ChatGPT、DALL-E）疊在 No/Low Code 上，常見能力：自動生程式、優化模板、數據分析建議、依文字生 UI、行銷文案、個人化 App 快速組裝。

易混：Copilot／Cursor 幫你寫 code ≠ 整個專案變成 No Code。能做出 Demo ≠ 能上生產（權限、log、備援、資料落地）。

3.1.2 產業場景（記「痛點→生成式能做什麼」）

產業	生成式 + No/Low Code 常出現的用法
醫療	分子結構預測輔助新藥、個人化療程草案、病歷整理與輔助診斷（醫師仍決策）
製造	設計方案生成、製程改善建議、原型加速
金融	情境模擬做風險、投資組合建議、合規監控輔助
零售	個人化行銷文案、庫存預測、推薦
教育	教材生成、個人化學習路徑、自動評量回饋
客服	虛擬客服、自動回覆草稿、客訴趨勢分析

改善客戶體驗的技術方案，選項出現 **NLP + 生成式回應** 通常比「預測性維護」更直接。

3.1.3 選平台的六大評估（必背標題）

1. **目標用戶與技術需求**：純業務拖放 → No Code；要複雜邏輯與企業整合 → Low Code。
2. **功能與擴展性**：能否接 CRM／ERP、自訂報表與工作流。
3. **安全性與合規**：加密、身分驗證、細緻權限。個資法／GDPR／CCPA 對得上。
4. **成本與效益**：**TCO**（購買、維護、培訓、隱性費用）與 **ROI**（縮短上市、效率）。只比授權單價是錯的。
5. **技術支援與社群**：文件、客服、論壇活不活。
6. **市場評價與案例**：同業成功案例，不要只看官網文案。

3.1.4 結合生成式的挑戰與解方

挑戰	典型症狀	解方方向
準確與可靠	幻覺、錯內容進生產	多層驗證：自動檢測 + 人工審核
隱私與安全	敏感資料進公有模型	加密、匿名、權限；禁止亂貼客戶名單
倫理	假訊息、訓練偏見	使用規範、公平性檢測
整合與效能	API 接不穩、GPU 不夠	開放 API 的平台、雲端分散負載

四個穩健面向：數據品質（多樣、定期更新）→ 模型多維評估（準確／可靠／創造性、壓力測試）→ **人機協作**（關鍵場景人工干預）→ 資安（防攻擊、弱點掃描）。

3.1.5 市場價值（選「效益敘述」用）

- 降低開發成本：少請一堆工程師做重複內部工具；業務能參與。
- 縮短上市：現成模組、API、敏捷改功能。
- 可擴展與訂價彈性：流量與功能成長時能調。

企業導入 AI 後**最直接**的影響，練習題方向是提升生產力與效率，不是「增加人力需求」或「降低競爭力」。

3.1.6 何時用、何時不用

較適合	較不適合
內部試作、表單、簡單自動化、兩週驗證值不值得做	核心交易、高風險核決、嚴格低延遲
標準連接器就夠	深度客製協定、要可移植避單一雲死鎖
業務先跑通流程	稽核與問責要求極高卻完全黑箱

治理不會因為 No Code 而消失。個資、權限、測試、問責一樣要做。

員工提升 AI 能力：跨部門交流＋測試專案，比「自己看心情自學」有效。教師帶學生用生成式：訂使用規範並說明，不是全面禁止或無限制。

3.2 生成式 AI 應用領域與工具使用

3.2.1 生成式是什麼

核心：學資料分布後**生成新內容**，不是只分析既有資料。常見骨架：GAN、VAE、Transformer。ChatGPT 2022-11 後把人機互動與產業應用推到前線。

技術架構三塊：

1. **深度學習網路**：多層特徵；**自注意力**處理長距離依賴。
2. **訓練資料處理**：清洗、**Tokenization**（切詞／子詞）、向量化。
3. **推理採樣（必考）**：

參數	作用	實務
Temperature	隨機性	低＝保守穩定（FAQ、合約草稿要準）；高＝較有創意（發想，仍要人審）
Top-k	只從機率最高的 k 個 token 抽	限制胡亂字

參數	作用	實務
Nucleus (Top-p)	從累積機率達閾值（如 0.9）的集合抽	比固定 k 更彈性

生成式特點：上下文理解、遷移學習、多模態、prompt 可控。挑戰：算力、幻覺、偏見、安全。演進：壓縮量化加速、模組化、領域微調、多模態融合。

3.2.2 市場與社會影響

- 規模成長、創業投資、訂閱與客製方案、永續（能耗）。
- 就業雙面：重複性工作被取代；新興職如提示工程師、AI 訓練師。
- 效益：直接（降本增效）、間接（新商業模式）、衍生（雲與硬體）。
- 迫切挑戰：資料隱私與倫理規範（指引練習方向），不是「算力過剩」。

生圖要同時考慮：解析度、**版權合法性**、推論時間——「以上皆是」。使用生成內容要標注來源、人工審查，不是直接當學術報告。

3.2.3 技術突破與工具趨勢（記方向不背價目）

突破：GAN 高品質圖；VAE／Flow 較穩的機率生成；Transformer＋Self-Attention（GPT、DALL-E、Stable Diffusion）；預訓練＋微調＋**RLHF**（人類回饋強化學習讓輸出更貼人）；推理加速（如 vLLM）、邊緣部署。

發展方向：

- 模型變大（LLM）＋多模態（文生圖 Midjourney、DALL-E）。
- 輕量化：壓縮、量化、個人化客製。
- GAN 與擴散融合提升真實感。
- 開源生態：Hugging Face 等加速整合。
- 垂直產業：法律文件、醫療報告、金融風控、教材。
- **AlaaS**：不用自備高階硬體，用 OpenAI API、Hugging Face Spaces。
- 可控性：微調＋提示工程＋風格參數。
- 協作與即時迭代。
- 安全：本地部署、加密、版權過濾。
- 道德法規：深偽、假新聞、標示 AI 生成。

工具怎麼選（評鑑與考題曾出現的用途，品牌會變，記用途）：

需求	方向
對話、草稿	對話型 LLM

需求	方向
系統整合、控 token	API
多模態理解	多模態模型
寫程式	Copilot、Cursor 類
流程／代理工作室	Copilot Studio 等 Low-Code 代理
生圖	Midjourney、DALL-E、SD 類
語音轉文字	Whisper 類

選項出現「要引用內部知識」→ **RAG 或有來源的檢索**，不是只調 temperature。

3.2.4 提示工程

技法	何時用
Zero-shot	簡單、模型已會
Few-shot	要固定格式、口吻、欄位
CoT 思維鏈	要逐步推理
ToT 思維樹	多分枝探索；成本高，簡單題不值得
角色／約束	限定專家角色、禁止事項、輸出 schema

Prompt 寫更長**救不了**知識不在上下文裡。知識會變 → RAG。行為／口吻要長期改變 → 才評估微調。

3.2.5 RAG vs 微調 vs Agent（公告題核心）

RAG (Retrieval-Augmented Generation)：先檢索再生成。解決知識過時與胡謔，讓答案可追溯到片段。

答得不準時檢查順序：

1. 資料有沒有、權限對不對
2. Chunking 切太碎／太長／切錯邊界
3. 檢索（關鍵字／向量／混合）
4. 才換更大模型

有搜尋框但沒把檢索片段餵給生成，不算完整 RAG。

微調 Fine-tuning：用領域資料改模型權重。適合穩定的格式、口吻、任務行為。成本高、資料要更新就再練。SOP 每月改 → **優先 RAG**，不是從零訓練或動不動全量微調。

PEFT／LoRA：參數高效微調，只訓少量適配參數，省算力與儲存。考「不想動全模型又要領域化」時選它。不是另一種 RAG。

Agent：感知 → 規劃 → 行動（呼叫工具／API）。要多步、查庫、開單、跨系統才需要。規則清楚的單次問答不必上 Agent。多代理要防互等卡死：逾時、heartbeat、failover，不是把 prompt 寫更長。

MCP (Model Context Protocol)：模型連外部工具／資料的協定思路——「怎麼接工具」，不是另一個 LLM 品牌，也不是 RAG 的替身。

選型口訣：

知識要新、要引用	→ RAG
口吻／格式要長期像我們	→ 微調（可 PEFT）
要動手呼叫系統	→ Agent（＋工具／MCP）
只要穩穩答一句	→ 單次 LLM＋低 temperature

3.2.6 應用領域（規劃題用「輔助不是取代」）

- 藝術設計：靈感與細節輔助，創作者仍負責構思；注意版權。
- 醫療生技：分子、合成影像、個人化建議、醫學教育模擬；診斷責任在醫師。
- 教育：個人化內容、助教、VR 教材；要使用規範。
- 娛樂媒體：地圖／劇本／虛擬主播；深偽風險。
- 產品製造：草圖、3D 原型、模擬報告、供應鏈預測。

生成式基礎技術選項裡，**GAN** 常是正確項（相對決策樹、聚類、隨機森林）。

3.3 生成式 AI 導入評估規劃

導入順序（寫得出來就能拿規劃題）：

問題與目標 → 資料能不能用 → 方案選擇 → 成本效益（TCO／ROI） → 試點測試 → 權限與監控 → 擴大。先選模型品牌是錯序。

對照文件方向：經濟部產業發展署《AI 導入指引》、公部門手冊、金管會金融業 AI 指引（看場景選）。

3.3.1 評估標準（五塊，第 3 塊標題已勘誤）

（1）需求與現狀

痛點、場景（品質、週期、體驗、供應鏈）、技術是否真能解核心問題。規則引擎就夠就不要硬上生成式。

(2) 資源與基礎設施（這一點才是資源）

人才、數據完整性與清洗、硬體／雲與資安、架構可擴展。資料品質差，再貴的模型也歪。

(3) 企業導入階段性實施策略（勘誤）

原文標題誤為「資源與基礎設施評估」（與第 2 點重複）。勘誤後本點是**分階段**：

- 試點：小範圍、可驗證、風險可控
- 階段擴大：依試點結果推廣
- 長期目標：納入企業策略
- 持續優化與回饋

不要把第 (2) (3) 點搞混。

(4) 員工技能與文化

分職能培訓、實務操作、鼓勵跨部門，而不是只買授權。

(5) 風險評估與管理

資料安全隱私、倫理法規、模型偏誤與失效應變、資金人力調度。

優先級：先做**低難度、快見效、不拖垮其他業務**的場景；資源需求高且短期難見效的延後。

三階段願景：

階段	重點
初始／試點	驗證真實場景、收回饋、累積經驗
成長／推廣	跨部門、從單點到多環節（內容→分析→客服→供應鏈）
成熟／創新	系統化營運、差異化、滾動對齊戰略

人才：內部課（LLM、微調、資料、怎麼選模型）＋外部專家／廠商縮短學習曲線。

3.3.2 規劃落地（準備 → 設計 → 營運）

準備：挑選方案

- 用營運數據、員工與客戶回饋找問題；先簡單可行（內部檢索、客服草稿）。
- 畫流程、找重複規則化工作當候選。
- 檢視資料是否夠、算力／儲存、人力技能；不夠就升級、外援或訓練。
- 方案：商業產品／開源／客製；看功能、適配、擴展、**成本結構（授權＋硬體＋營運＋隱性）**、支援評價。
- 優先順序：商業價值、技術成熟、資源、是否符合長期戰略。

設計：確認規格

- 可量化 KPI（初判正確率、處理時間、錯誤率）。
- POC：小規模看準確率、效率、能否融入現況、員工會不會用。
- 算 ROI 與回收週期；有效再擴大。

營運

人員會用、持續監控、效能掉或環境變就微調或重訓。資料漂移要能被發現；最好有重訓管道，達警戒值觸發更新。價值擴散：內部分享、培訓、獎勵，從單點到全公司。

3.3.3 風險管理（科目二最高頻）

三大塊：倫理與偏見、資料安全隱私、合規與智財。

風險	規劃師動作
個資／機密進公有模型	禁傳、私有化、最小化、契約與 log
訓練資料被模型背出來	去識別、差分隱私、存取控制
提示攻擊／注入	Guardrail、權限分離、秘密不放進 prompt
對抗性輸入	監控、過濾、紅隊
幻覺當官方回覆	RAG、引用、低 temperature、人工放行
偏見歧視	多樣資料、公平測試、申訴與覆核
智財／深偽	訓練與輸出授權、標示 AI 生成、內容過濾
高風險場景問責	RACI：誰能上線、誰覆核、誰能關機；醫療金融責任不能丟給模型
反向工程推訓練資料	限流、監控異常查詢

高風險項目優先緩解：加強審核、偏見檢測、透明標示「此內容由 AI 生成」。定期審核＋員工風險意識訓練。

TCO 提醒：便宜模型省 token，可能增加覆核人力，總成本未必低。試點成功 ≠ 全面上線（權限、備援、營運人力沒跟上）。

3.3.4 科目二解題習慣

1. 這題該不該用 AI？規則是否就夠？
2. 鑑別／生成／RAG／Agent／Low-Code 哪個**夠用就好**？
3. 資料能不能出域？誰覆核？
4. 「最不適當」常是：全公司一個公有 GPT 不加分級、試點沒過就全面、只比 API 單價、無限制讓學生用 AI 交作業、生成內容不標來源、導入先選最潮模型。

科目二閉卷清單

- No Code vs Low Code 各一句；六大評估能默寫標題。
- TCO 含哪些成本。
- Temperature／Top-k／Nucleus 各管什麼。
- RAG vs 微調 vs Agent vs LoRA vs MCP。
- 導入五評估＋勘誤後第（3）點標題。
- 試點 → 擴大 → 成熟。
- 個資、幻覺、提示攻擊、問責各一個控制措施。

補篇 A | 工具與架構（公告題比指引細）

A.1 RAG 實務坑

長文件整份丟進檢索 → 噪音大、找不到關鍵句。要 **chunking**（按標題、段落、重疊窗口切）。切太碎失去脈絡，切太長檢索變鈍。

法規常更新：優先更新索引與文件版本，不是每次全量微調。檢索不到新函釋，再大的模型也會講舊法。

高流量 RAG：快取常見問、非同步建索引、混合檢索（關鍵字＋向量）。延遲高時先查檢索與 rerank，不要先換 10 倍參數的模型。

表格／Excel：模型吃「原始格子」常亂。先轉成清楚的文字或 markdown 表、標欄位名，再送 LLM。

A.2 MCP vs RAG vs Agent

	解決什麼	不是什麼
RAG	把外部知識片段塞進生成上下文	不是自動去呼叫任意 API 辦事
MCP	模型如何標準化接上工具與資料源	不是另一家 LLM、也不是檢索演算法
Agent	多步規劃、選工具、看結果再行動	不是把 prompt 寫長就會規劃

情境感知 Agent：依當前對話／環境狀態選下一步，**不是**每次重訓模型。

Solution Graph：把複雜任務拆成節點（步驟／工具）與邊（依賴），方便規劃與失敗重試。

多 Agent 互等：加超時、重試上限、人工接管，不是加更長系統提示。

A.3 微調與 PEFT

企業專屬知識要寫進權重，但 GPU 很小 → LoRA／QLoRA／Adapter 等 PEFT，不是先買一排 A100 再全量微調。

內部 SOP 月月改 → RAG 為主。

要固定「我們公司的回覆口吻與欄位」→ 微調或強 prompt+few-shot。

新市場資料跟 few-shot 差很多 → 補該市場例子或檢索該市場知識，不是把 temperature 調到 1.5。

RLHF：用人類偏好排比來對齊輸出，適合「已會說話但不合規範」。

A.4 生成品質與出處

同一偏好設定下不同族群推薦差異過大 → 查資料偏見與公平，不是只加更多生成多樣性。

客服「整體 QPS 很高但仍卡頓」→ 可能是解碼延遲、排隊、未串流（streaming）；吞吐高 ≠ 單筆延遲低。

影片／圖像出處證明（provenance）：浮水印、內容憑證、元資料。考「何者不屬於官方機制」時，把「完全無法被偽造所以不用審」這類絕對句當錯的。

GPT-Realtime 類：適合語音／低延遲互動，不適合大型離線批報表。

程式輔助工具：在編輯器裡依上下文建議程式碼，仍要人審與測試；不是自動擁有著作權或保證無漏洞。

Vibe coding／MVP：快，但缺測試、權限、可維護性時，不能直接當生產。

A.5 Low-Code 進階判斷

儀表板要「分析可信」→ 權限列級、資料來源可追溯、計算邏輯不可被亂改，不是只選最漂亮的圖。

部門自建應用擴大後：統一身分、稽核 log、資料分類、防止影子 IT 把名單貼到公有模型。

邊緣運算+No/Low Code：設備端要考慮斷線、模型套件大小、延遲；不是所有邏輯都回雲端。

門市主管自己改看板 vs 行銷建預測模型：前者 No Code BI；後者常要資料科學／AutoML／Low Code ML，深度不同。

A.6 導入補充

資料漂移：上線後輸入分佈變了，監控特徵與輸出，達門檻重訓。

自動化重訓管道：警戒值觸發，減少人工作業時間，但仍要驗證才能上生產。

高風險（授信、醫療生成建議）：人審、可解釋、申訴、不能把責任寫成「AI 說的」。

生成內容當對外官方：引用、標示 AI、法務看智財。

補篇 B | 指引風格自測

1. 生圖要考慮：解析度、版權、推論時間（常為以上皆是）。
2. 教師帶學生：訂規範並說明，不是禁或放任。
3. 改善客戶體驗：NLP+生成式回應。
4. 員工能力：跨部門交流與測試專案。
5. 導入後最直接影響：生產力與效率。
6. 生成式基礎技術之一：GAN。
7. 迫切挑戰：隱私與倫理。
8. 生成內容品質：標來源、要人審。
9. 使用體驗優化**不是**「限制使用者自訂」。

導入題自己用話講一遍：需求 → 資源基礎設施 → **階段性實施（試點擴大）** → 文化人才 → 風險。第 3 點標題不要寫成資源評估。

補篇 C | 科目二判斷卡

選方法

- 內部知識要可引用、常更新 → RAG。
- GPU 不夠還要領域化 → PEFT/LoRA。
- 要查庫、開單、跨系統 → Agent。
- 只要穩答 FAQ → 低 temperature+RAG，不必 Agent。
- MCP 是接工具的協定；RAG 是塞知識。

風險紅線

- 客戶名單進公有 ChatGPT → 擋。
- 無人工的自動拒貸/自動診斷結論 → 擋。
- Low-Code 上了核心計費 → 鎖定、稽核、正確性風險。
- 只比 token 單價 → 忽略覆核 TCO。
- 試點沒過就全公司一個 GPT → 錯序。

提示

- 要穩定：降 temperature、加格式範例。
- 要推理：CoT。
- 要探索方案：ToT，貴。

- 知識不在上下文：檢索，不是把 prompt 再寫兩倍。

樂雲場景對答案

- 業務要自己做 GPT 客服：Low-Code 可試點；客戶資料、提示外洩、升級路徑先畫紅線。
- SOP 月更：RAG。
- 方案建議書草稿：生成；雲端用量是否異常：鑑別。
- 全公司一個 GPT：先分級（公開網／內部 RAG／禁止上傳）再談工具名。

補篇 D | 兩科交界（避免考場卡在「這科還是那科」）

科目一問原理與選學習類型、XAI、統計。

科目二問怎麼導入、哪種生成工具鏈、No/Low Code、風險控制。

同一件事兩科問法：

場景	科目一	科目二
客服機器人	鑑別意圖＋生成回覆	RAG、人審、個資、要不要 Agent
授信	監督式分類、SHAP／反事實、HITL	能不能全自動、合規、TCO
內部規章問答	Transformer／幻覺原理	RAG vs 微調、權限、引用
產線瑕疵	CNN、類別不平衡、Recall	邊緣、Low-Code 試點、監控漂移

準備時兩科筆記都讀，W9 起才用題本計時。題目在 04-題本，進度在 01-讀書進度計畫表。